HỌC MÁY (MACHINE LEARNING)

Nguyễn Thị Hải Bình

Email: nth.binh@hutech.edu.vn

Nội dung chính của bài học

1. Học máy là gì?

2. Quy trình học máy

3. Ứng dụng của học máy


4. Phân loại thuật toán học máy

5. Bài toán phân lớp


6. Bài toán gom cụm dữ liệu

HỌC MÁY LÀ GÌ?

- Phát biểu bài toán:
 - Biết chiều dài và chiều rộng của cánh hoa và đài hoa.
 - Hãy cho biết đó là loài hoa iris nào.



- Để giải bài toán phân loại hoa iris, các nhà nghiên cứu thực hiện đo lường và ghi lại chiều dài và chiều rộng của cánh hoa và đài hoa của 150 bông hoa iris.
- Mỗi bông hoa iris thuộc một trong ba loài setosa, versicolor, hoặc virginica.






Không sử dụng học máy


- Các nhà nghiên cứu sử dụng bộ dữ liệu gồm 150 quan sát và phân tích.
- Sau khi quan sát giá trị lớn nhất, nhỏ nhất của độ dài cánh hoa và đài hoa của mỗi loại hoa, các nhà nghiên cứu đưa ra quy tắc để phân loại hoa iris như sau:


 Ba quy tắc R1, R2, R3 sẽ được sử dụng để máy tính (AI) dự đoán tên loài của hoa iris.


Sử dụng học máy

- 150 quan sát được đưa vào một thuật toán (gọi là thuật toán học máy).
- Thuật toán học máy sẽ sinh ra một tập các quy tắc (hay một mô hình) dùng để dự đoán tên loài của hoa iris.









Học máy là gì?

"Learning is any process by which a system improves performance from experience."

- Herbert Simon

Definition by Tom Mitchell (1998):

Machine learning is the study of algorithms that:

- improve their performance *P*
- at some task T
- with experience *E*

A well-defined learning task is given by $\langle P, T, E \rangle$

Definition of machine learning


Machine learning is the study of algorithms that improve their performance P at some task T with experience E.


Handwritten digit recognition


T: Recognizing hand-written words

P: Percentage of words correctly classified

E: Database of human-labeled images of handwritten digits







Since an early flush of optimism in the 1950s, smaller subsets of artificial intelligence – first machine learning, then deep learning, a subset of machine learning – have created ever larger disruptions.

When Do We Use Machine Learning?




ML is used when:

- Human expertise does not exist (navigating on Mars)
- Humans can't explain their expertise (speech recognition)
- Models must be customized (personalized medicine)
- Models are based on huge amounts of data (genomics)









Learning isn't always useful:


There is no need to "learn" to calculate payroll

Examples of tasks that are best solved by using a learning algorithm

- Recognizing patterns:
 - Facial identities or facial expressions
 - Handwritten or spoken words
 - Medical images
- Generating patterns:
 - Generating images or motion sequences
- Recognizing anomalies:
 - Unusual credit card transactions
 - Unusual patterns of sensor readings in a nuclear power plant
- Prediction:
 - Future stock prices or currency exchange rates

Stock price prediction





Machine translation





Recommender systems



People who bought Hastie ...


Frequently Bought Together

Customers buy this book with <u>Pattern Recognition and Machine Learning (Information Science and Statistics) (Information Science and Statistics)</u> by Christopher M. Bishop





Price For Both: £104.95



Customers Who Bought This Item Also Bought

Page 1





Pattern Recognition and Machine Learning (Infor... by Christopher M. Bishop 本文文章 (4) £48.96

+ Show related items



MACHINE LEARNING (Mcgraw-Hill International Edit) by Thom M. Mitchell 会会会会(3) £42.74

+ Show related items



Pattern Classification, Second Edition: 1 (A Wi... by Richard O. Duda 会社会会(1) £78.38

+ Show related items



Data Mining: Practical
Machine Learning Tools a...
by Ian H. Witten


♣ Show related items

Medical Diagnosis

- Inputs: relevant info about patient, symptoms, test results, etc.
- Output: Expected illness or risk factors




Interpreting Brainwaves



Speech Recognition






Slide credit: Li Deng, MS Research

Azure Face API from Microsoft

 The Face API can detect human faces in an image and return the rectangle coordinates of their locations.



Azure Face API from Microsoft



Target face



Find similar faces


The Find Similar API takes a target face, and a set of candidate faces and finds a smaller set of faces that look most similar to the target face.



Candidate faces

Face API from Google





Autonomous Cars



Deep Learning in the Headlines



BUSINESS NEWS



Is Google Cornering the Market on Deep Learning?

A cutting-edge corner of science is being wooed by Silicon Valley, to the dismay of some academics.

By Antonio Regalado on January 29, 2014



How much are a dozen deep-learning researchers worth? Apparently, more than \$400 million.

This week, Google reportedly paid that much to







INNOVATION INSIGHTS

community content



Deep Learning's Role in the Age of Robots



BloombergBusinessweek Technology

The Race to Buy the Human Brains Behind **Deep Learning Machines**


By Ashlee Vance January 27, 2014

intelligence projects. "DeepMind is bona fide in terms of its research capabilities and depth," says Peter Lee, who heads Microsoft Research.


According to Lee, Microsoft, Facebook (FB), and Google find themselves in a battle for deep learning talent. Microsoft has gone from four full-time deep learning experts to 70 in the past three years. "We would have more if the talent was there to




Machine Learning




Deep Learning





This image is licensed under CC BY-NC-SA 2.0; changes made




- Action classification
- Image captioning





This image is licensed under CC BY-SA 2.0; changes made

Person Hammer







Types of Learning



Supervised (inductive) learning

Given: training data + desired outputs (labels)

Unsupervised learning

Given: training data (without desired outputs)

Semi-supervised learning

• Given: training data + few desired outputs


Reinforcement learning

Rewards from sequence of actions

Supervised Learning: Regression




- Given $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$
- Learn a function f(x) to predict y given x
 - *y* is real-valued == regression



Supervised Learning: Classification




- Given $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$
- Learn a function f(x) to predict y given x
 - *y* is categorical == classification



Supervised Learning

- x can be multi-dimensional
 - Each dimension corresponds to an attribute




- Clump Thickness
- Uniformity of Cell Size
- Uniformity of Cell Shape

•••

Unsupervised Learning




- Given $x_1, x_2, ..., x_n$ (without labels)
- Output hidden structure behind the x's
 - E.g., clustering



Unsupervised Learning



Genomics application: group individuals by genetic similarity




Unsupervised Learning






Organize computing clusters



Social network analysis




Market segmentation



Astronomical data analysis

Reinforcement Learning

- Given a sequence of states and actions with (delayed) rewards, output a policy
 - Policy is a mapping from state → actions that tells you what to do in a given state



Reinforcement Learning



A robot learns about the paths through a maze.


The robot starts from the lower left corner of the maze.

Each location (state) is indicated by a number. There are four action choices (left, right, up, down).


When the robot hits a wall, it receives reward -1.

When it reaches an open location, it receives reward o.

When it reaches the exit, it receives reward 100.



Reinforcement Learning




Quy trình học máy




- Quy trình học máy chia làm 2 giai đoạn
- Giai đoạn huấn luyện (training/learning)
 - Sử dụng một bộ dữ liệu huấn luyện để xây dựng tập quy tắc (hoặc mô hình) để giải bài toán.
- Giai đoạn thử nghiệm (testing)
 - Kiểm nghiệm tập quy tắc (hoặc mô hình) xây dựng được ở giai đoạn huấn luyện trên một bộ dữ liệu (gọi là bộ dữ liệu kiểm chứng)
 - Một số phương pháp đánh giá mô hình phổ biến: độ chính xác (accuracy), confusion metric, precision, recall, F1-Score, MSE.

BÀI TOÁN PHÂN LỚP (CLASSIFICATION)

Giai đoạn huấn luyện (training phase)



Giai đoạn kiểm nghiệm (testing phase)



Thuật toán phân lớp


- Cây quyết định (Decision tree)
- Bộ phân lớp Bayes (Naive Bayes)
- Hồi quy logistic (Logistic regression)
- Random forests
- Mang neuron

• ...

CÂY QUYẾT ĐỊNH

Biểu diễn cây quyết định





Ví dụ: Cây quyết định cho bài toán PlayTennis

Bộ dữ liệu huấn luyện


Day	Outlook	Temperature	Humidity	Wind	Playtennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

Decision Tree for PlayTennis

Day	Outlook	Temperature	Humidity	Wind	Playtennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

All observations in the data set are perfectly described by the tree.

Question: How do we build such trees?



Xây dựng cây quyết định


Thuật toán xây dựng cây quyết định nhỏ nhất là bài toán thuộc nhóm NP-problem.

- Áp dụng giải thuật tham lam để xây dựng cây quyết định:
 - Khởi tạo cây quyết định rỗng
 - Lần lượt chọn các thuộc tính tốt nhất để đưa vào cây quyết định.
 - Lặp tới khi cây quyết định được xây dựng xong.
- Thế nào là thuộc tính tốt nhất?
 - Sử dụng lý thuyết Entropy để xác định.

Entropy




- $S = b\hat{o} d\tilde{u}$ liệu huấn luyện.
 - S gồm các quan sát thuộc một trong hai lớp + (positive) hoặc (negative).
- p_{\oplus} = số lượng quan sát thuộc lớp positive / tổng số quan sát.
- p_{\odot} = số lượng quan sát thuộc lớp negative / tổng số quan sát.
- $Entropy(S) = -p_{\oplus} \log_2 p_{\oplus} p_{\ominus} \log_2 p_{\ominus}$
- Entropy đo lường độ đồng nhất của S.




Entropy





Bộ dữ liệu có tính đồng nhất thấp

$$-\frac{4}{9}\log_2\frac{4}{9} - \frac{5}{9}\log_2\frac{5}{9} \approx 0.99$$




Bộ dữ liệu có tính đồng nhất cao

$$-\frac{8}{9}\log_2\frac{8}{9} - \frac{1}{9}\log_2\frac{1}{9} \approx \frac{1}{2}$$




Cách tìm thuộc tính tốt nhất?





• Let p is a parent node, p is split into k partitions, n_i is number of records in partition $i, n = \sum_{i=1}^k n_i$.

$$GAIN = Entropy(p) - \sum_{i=1}^{\kappa} \frac{n_i}{n} Entropy(i)$$










$$GAIN = Entropy(p) - \sum_{i=1}^{\kappa} \frac{n_i}{n} Entropy(i)$$





Which attribute is the best classifier?

ID3 Algorithm



 $ID3(Examples, Target_attribute, Attributes)$

- Create a Root for the tree
- If all examples are positive, Return single-node tree Root, with label = +
- If all examples are negative, Return single-node tree Root, with label = -
- If Attributes is empty, Return single-node tree Root, with label = most common value of $Target_attribute$ in Examples
- otherwise, Begin

 - \bullet decision attribute for $Root \leftarrow A$
 - **Proof** For each possible value v_i of A
 - ightharpoonup Add new branch below Root with $A = v_i$
 - ullet Let $Examples_{v_i}$ be the subset of Examples with v_i for A
 - If Examples is empty
 - Then add a leaf node with label = most common value of $Target_attribute \text{ in } Examples$
 - · Else add ID3($Examples_{v_i}$, $Target_Attribute$, $Attributes \{A\}$)
- Return Root

Ví dụ



Day	Outlook	Temperature	Humidity	Wind	Playtennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No



Bài tập



Age	Income	Student	Credit_rating	Buys_computer
<=30	High	No	Fair	No
<=30	High	No	Excellent	No
3140	High	No	Fair	Yes
>40	Medium	No	Fair	Yes
>40	Low	Yes	Fair	Yes
>40	Low	Yes	Excellent	No
3140	Low	Yes	Excellent	Yes
<=30	Medium	No	Fair	No
<=30	Low	Yes	Fair	Yes
>40	Medium	Yes	Fair	Yes
<=30	Medium	Yes	Excellent	Yes
3140	Medium	No	Excellent	Yes
3140	High	Yes	Fair	Yes
>40	Medium	No	Excellent	No

Bài tập

- Cho tập dữ liệu huấn luyện được thể hiện trong bảng sau:
- Xây dựng cây quyết định hai mức dự đoán một chuyến bay có bị chậm trễ không
- Tính error rate trên tập dữ liệu huấn luyện.

Thuộc	Giá trị của thuộc	Số lượng chuyến	Số lượng chuyến
tính	tính	bay bị trễ	bay không bị trễ
Mưa	YES	30	10
Mua	NO	10	30
Gió	YES	25	15
GIO	NO	15	25
Mùa hè	YES	5	35
iviua ne	NO	35	5
Mùa	YES	20	10
	NO	20	30
đông	NO	25	30

BỘ PHÂN LỚP BAYES

Định lý Bayes



Likelihood

Prior

$$P(Y|X_1,\ldots,X_n) = \frac{P(X_1,\ldots,X_n|Y)P(Y)}{P(X_1,\ldots,X_n)}$$

Normalization Constant

$$P(X_1,\ldots,X_n|Y)=\prod_{i=1}^n P(X_i|Y)$$
 (Giả sử X1, ..., Xn là độc lập theo điều kiện Y)

Day	Outlook	Temperature	Humidity	Wind	Playtennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

		A new day		
outlook	temperature	humidity	windy	play
sunny	cool	high	true	?

Cần tính:

P(play = Yes | outlook = sunny, temperature = cool, humidity = high, windy = true)

P(play = No | outlook = sunny, temperature = cool, humidity = high, windy = true)

Huấn luyện bộ phân lớp Bayes



• Tính P(Y=v):

$$P(Y=v) = \frac{Count(Y=v)}{\# \ records}$$

• Tính $P(X_i=u|Y=v)$:

$$P(X_i = u | Y = v) = \frac{Count(X_i = u \land Y = v)}{Count(Y = v)}$$

	The weather data, with counts and probabilities												
out	look		tem	perat	ure	hur	nidity		\	windy	,	pl	ay
	yes	no		yes	no		yes	no		yes	no	yes	no
sunny	2	3	hot	2	2	high	3	4	false	6	2	9	5
overcast	4	0	mild	4	2	normal	6	1	true	3	3		
rainy	3	2	cool	3	1								
sunny	2/9	3/5	hot	2/9	2/5	high	3/9	4/5	false	6/9	2/5	9/14	5/14
overcast	4/9	0/5	mild	4/9	2/5	normal	6/9	1/5	true	3/9	3/5		
rainy	3/9	2/5	cool	3/9	1/5								

$$P(play = Yes) = 9/14$$

$$P(play = No) = 5/14$$

$$P(\text{outlook} = \text{sunny} | \text{play} = \text{yes}) = 2/9$$

$$P(\text{outlook} = \text{sunny} | \text{play} = \text{no}) = 3/5$$

$$P(\text{outlook} = \text{overcast} \mid \text{play} = \text{yes}) = 4/9$$

$$P(\text{outlook} = \text{overcast} \mid \text{play} = \text{no}) = 0/5$$

$$P(\text{outlook} = \text{rainy} | \text{play} = \text{yes}) = 3/9$$

$$P(\text{outlook} = \text{rainy} \mid \text{play} = \text{no}) = 2/5$$

Cần tính:

```
P(play = Yes | outlook = sunny, temperature = cool, humidity = high, windy = true)
= \frac{P(\text{outlook} = \text{sunny, temperature} = \text{cool, humidity} = \text{high, windy} = \text{true}|\text{play} = \text{Yes}) \times P(\text{play} = \text{Yes})}{\text{res}}
  \underline{P(\text{outlook = sunny}|\text{play = Yes})} \times P(\text{temperature = cool}|\text{play = Yes}) \times P(\text{humidity = high}|\text{play = Yes}) \times P(\text{windy = true}|\text{play = Yes}) \times P(\text{play = Yes}) \times P(\text{pla
                                                                                                                                                                                                                                                                                                                                                                                                                              Μ
P(play = No | outlook = sunny, temperature = cool, humidity = high, windy = true)
  = \frac{P(\text{outlook} = \text{sunny, temperature} = \text{cool, humidity} = \text{high, windy} = \text{true}|\text{play} = \text{No}) \times P(\text{play} = \text{No})
    P(\text{outlook} = \text{sunny}|\text{play} = \text{No}) \times P(\text{temperature} = \text{cool}|\text{play} = \text{No}) \times P(\text{humidity} = \text{high}|\text{play} = \text{No}) \times P(\text{windy} = \text{true}|\text{play} = \text{No}) \times P(\text{play} = \text{No})
                                                                                                                                                                                                                                                                                                                                                                                                                      Μ
```

```
P(outlook = sunny, temperature = cool, humidity = high, windy = true|play = Yes) x P(play = Yes)
=\frac{2}{9}\times\frac{3}{9}\times\frac{3}{9}\times\frac{3}{9}\times\frac{9}{14}
= 0.0053
P(outlook = sunny, temperature = cool, humidity = high, windy = true|play = No) x P(play = No)
=\frac{3}{5}\times\frac{1}{5}\times\frac{4}{5}\times\frac{3}{5}\times\frac{5}{14}
= 0.0206
P(play = Yes | outlook = sunny, temperature = cool, humidity = high, windy = true)
= 0.0053 / (0.0053 + 0.0206)
= 0.205
P(play = No | outlook = sunny, temperature = cool, humidity = high, windy = true)
= 0.0206 / (0.0053 + 0.0206)
= 0.795
\rightarrow Dư đoán: play = No
```

Bài tập




Thuộc	Giá trị của thuộc	Số lượng chuyến	Số lượng chuyến
tính	tính	bay bị trễ	bay không bị trễ
Mưa	YES	30	10
Mua	NO	10	30
Gió	YES	25	15
GIO	NO	15	25
Mùa hè	YES	5	35
Mua He	NO	35	5
Mùa	YES	20	10
	NO	20	30
đông	NO	25	30

GOM CỤM DỮ LIỆU

Học có giám sát (supervised learning)







Dữ liệu huấn luyện: $\{(x^{(1)},y^{(1)}),(x^{(2)},y^{(2)}),(x^{(3)},y^{(3)}),\dots,(x^{(m)},y^{(m)})\}$

Học không giám sát (unsupervised learning)








Dữ liệu huấn luyện: $\{x^{(1)}, x^{(2)}, x^{(3)}, \dots, x^{(m)}\}$





THUẬT TOÁN K-MEANS























Thuật toán K-means



Input:

- K (số lượng cụm)
- Dữ liệu huấn luyện: $\{x^1, x^2, ..., x^m\}$

Các bước của thuật toán:

- Khởi tạo trọng tâm của K cụm: $m_1, m_2, ..., m_k$
- Lặp tới khi trọng tâm cụm không thay đổi:
 - Với mọi $i \in [1, m]$, gán x^i vào phân cụm có trọng tâm gần x^i nhất.
 - Tính lại trọng tâm của mỗi cụm.

Ví dụ



• Gom dữ liệu sau thành 2 cụm dựa trên weight index và pH.

Object	Weight index	рН
Medicine A	1	1
Medicine B	2	1
Medicine C	4	3
Medicine D	5	4